Relatório Final – Comparação de Classificadores em Ciência de Dados

Alunos:

- Guilherme Gomes Alves – 12311BSI306
- Vinícius Ferreira Salge - 12311BSI308

---

a. Introdução e Objetivos

O campo da Ciência de Dados oferece ferramentas poderosas para extrair conhecimento e tomar decisões a partir de grandes volumes de informação. Uma das tarefas mais comuns e impactantes é a classificação, que consiste em atribuir rótulos ou categorias a novos dados com base em um modelo treinado a partir de dados históricos. A eficácia de um modelo de classificação depende não apenas da qualidade dos dados, mas também da escolha do algoritmo e de uma avaliação criteriosa de seu desempenho.

O objetivo principal deste trabalho é aplicar, avaliar e interpretar o desempenho de três algoritmos de classificação supervisionada em duas bases de dados públicas e distintas. Buscamos, através de uma metodologia estruturada, realizar o pré-processamento detalhado dos dados, justificar a escolha dos algoritmos, e conduzir uma avaliação crítica dos resultados para determinar o modelo mais eficaz para cada problema proposto.

b. Descrição Detalhada das Bases de Dados

Foram escolhidas duas bases de dados públicas do repositório da UCI (University of California, Irvine) para esta análise.

Base de Dados 1: Heart Disease UCI (Doenças Cardíacas)

- **Link da Fonte:** `https://archive.ics.uci.edu/ml/machine-learning-databases/heart-disease/processed.cleveland.data`
- **Objetivo Principal:** O objetivo primário desta base de dados é prever a presença de doença cardíaca em um paciente com base em diversos atributos clínicos e demográficos.

É uma tarefa de classificação binária, onde o alvo é prever a presença (1) ou ausência (0) da doença.

- **Origem dos Dados:** Esta base de dados é oriunda do repositório UCI Machine Learning e é um subconjunto de dados coletados no Cleveland Clinic Foundation.
- **Descrição:** Esta base de dados tem como objetivo principal prever a presença de doença cardíaca em um paciente com base em atributos clínicos.
  - **Número de Instâncias:** 303
  - **Número de Atributos:** 13 atributos preditores e 1 atributo alvo (`target`).
  - **Tipos de Dados:**
    - `age`: Idade do paciente. Tipo: float64 (numérico)
    - `sex`: Sexo do paciente (1 = masculino, 0 = feminino). Tipo: float64 (categórico/numérico)
    - `cp`: Tipo de dor no peito (angina). Tipo: float64 (categórico/numérico)
    - `trestbps`: Pressão arterial em repouso. Tipo: float64 (numérico)
    - `chol`: Colesterol sérico em mg/dl. Tipo: float64 (numérico)
    - `fbs`: Açúcar no sangue em jejum > 120 mg/dl (1 = verdadeiro, 0 = falso). Tipo: float64 (categórico/numérico)
    - `restecg`: Resultados do eletrocardiograma em repouso. Tipo: float64 (categórico/numérico)
    - `thalach`: Frequência cardíaca máxima atingida. Tipo: float64 (numérico)
    - `exang`: Angina induzida por exercício (1 = sim, 0 = não). Tipo: float64 (categórico/numérico)
    - `oldpeak`: Depressão do segmento ST induzida pelo exercício em relação ao repouso. Tipo: float64 (numérico)
    - `slope`: A inclinação do segmento ST do pico do exercício. Tipo: float64 (categórico/numérico)
    - `ca`: Número de vasos principais coloridos por fluoroscopia (0-3). Tipo: float64 (categórico/numérico)
    - `thal`: Um distúrbio sanguíneo chamado talassemia. Tipo: float64 (categórico/numérico)

    - `target`: Presença de doença cardíaca (0 = ausência, 1 = presença). Tipo: int64 (categórico/numérico)

- **Valores Ausentes:** Na sua forma original, a base apresentava 4 valores ausentes na coluna `ca` e 2 na coluna `thal`.

Visualização das informações :

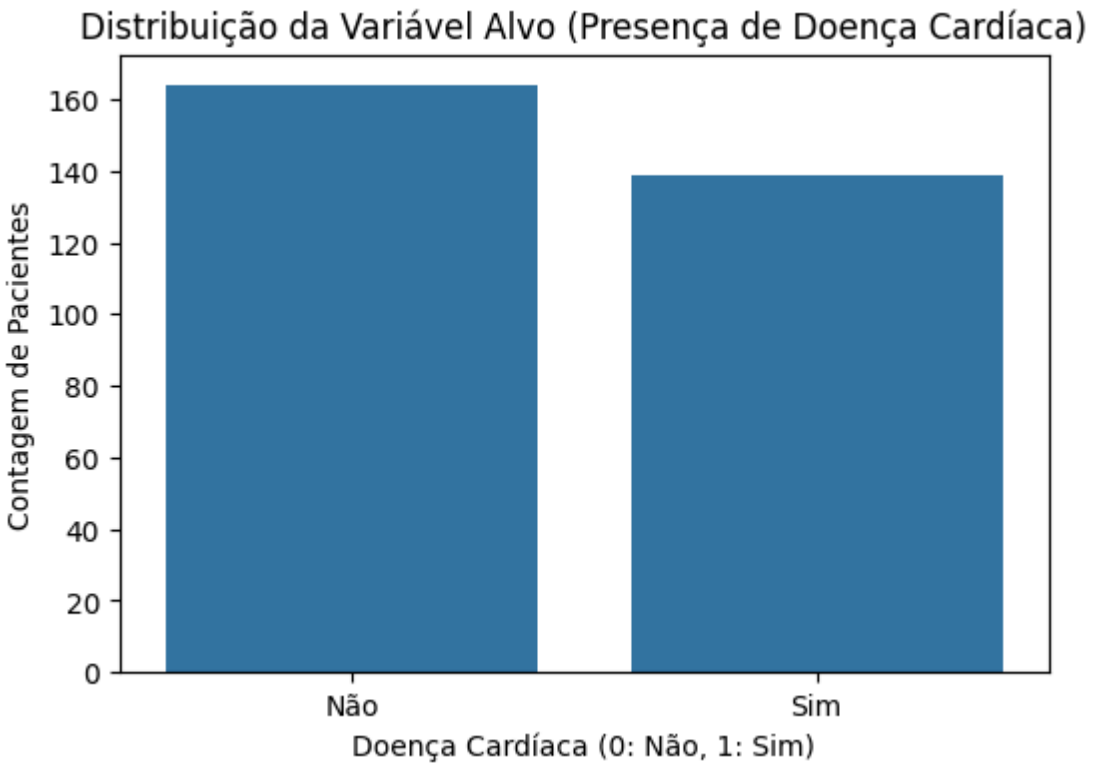

O gráfico de barras acima mostra o número de pacientes em cada categoria da variável `target`. Observamos que há **164 pacientes sem doença cardíaca (0)** e **139 pacientes com doença cardíaca (1)**. A distribuição está relativamente equilibrada, o que é bom para a maioria dos algoritmos de classificação, embora um leve desbalanceamento possa ser considerado em etapas posteriores, se necessário.

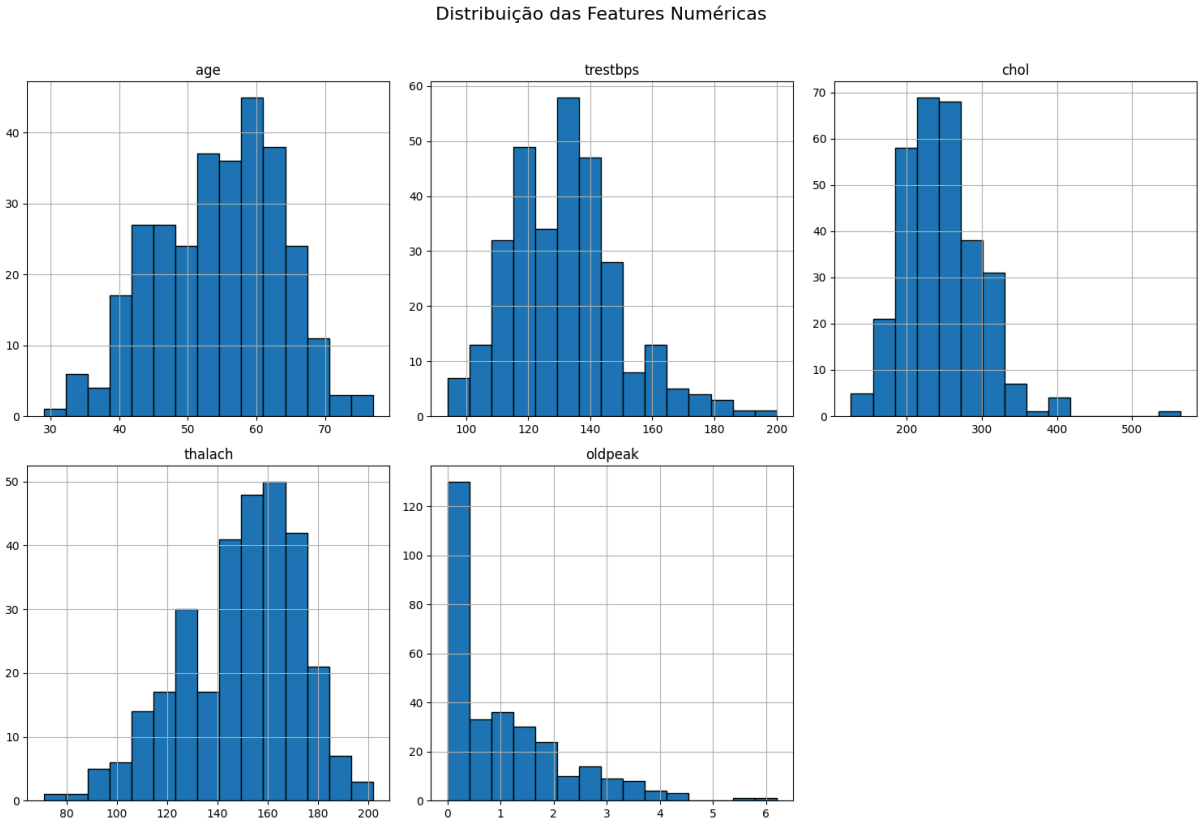

Os histogramas acima exibem a distribuição de frequência das features numéricas:

- **age**: A idade parece ter uma distribuição próxima do normal, com a maioria dos pacientes entre 40 e 65 anos.
- **trestbps** (Pressão Arterial em Repouso): A distribuição parece ligeiramente inclinada para a direita, com a maioria dos valores entre 120 e 140 mmHg.
- **chol** (Colesterol Sérico): A distribuição é inclinada para a direita, com alguns valores altos que podem ser considerados outliers. A maioria dos pacientes tem colesterol entre 200 e 300 mg/dl.
- **thalach** (Frequência Cardíaca Máxima Atingida): A distribuição parece próxima do normal, centrada em torno de 150-160 bpm.
- **oldpeak** (Depressão do Segmento ST): Esta variável tem uma distribuição assimétrica, com um pico significativo em 0.0 e valores se estendendo para a direita.

Estes gráficos nos dão uma ideia da variabilidade e dos valores típicos de cada feature numérica.

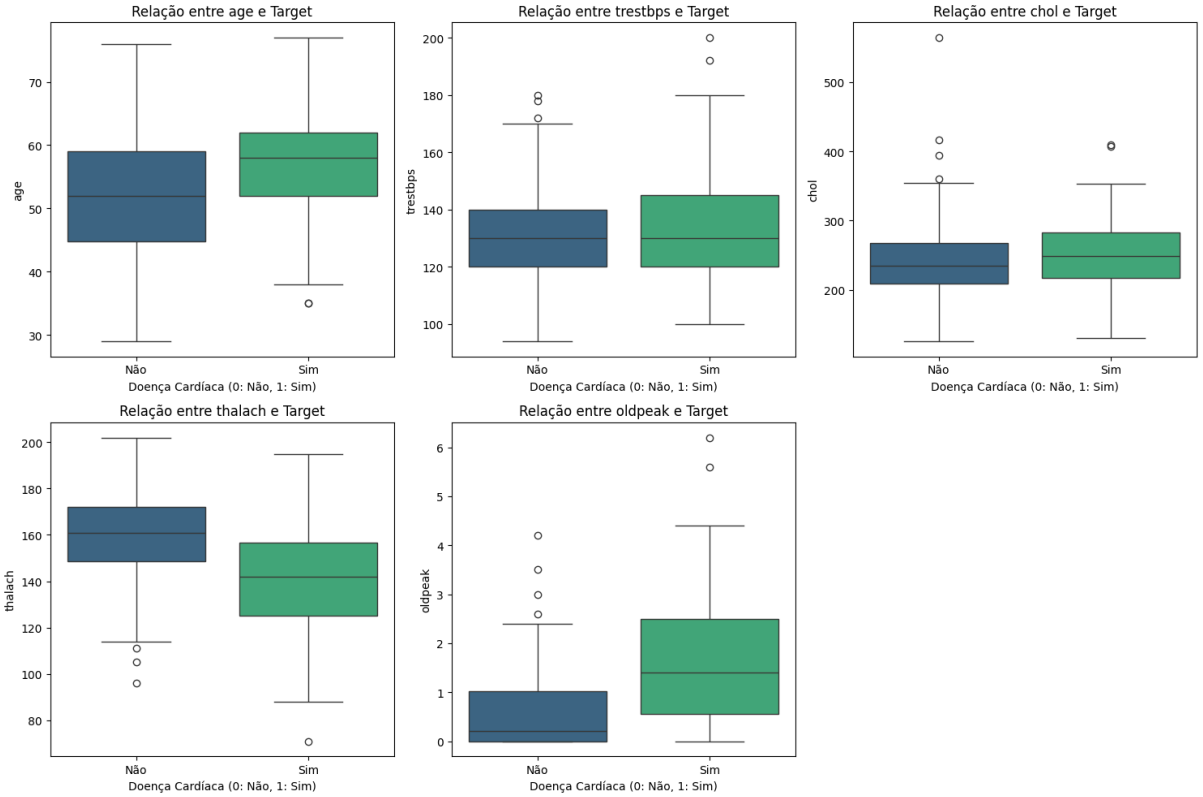

Os boxplots comparam a distribuição das features numéricas entre os grupos de pacientes com e sem doença cardíaca:

- **age**: A mediana da idade parece ser um pouco maior no grupo com doença cardíaca, mas as caixas de distribuição se sobrepõem consideravelmente.
- **trestbps** (Pressão Arterial em Repouso): As medianas e caixas de distribuição são bastante semelhantes entre os dois grupos.
- **chol** (Colesterol Sérico): Similar à pressão arterial, não há uma diferença marcante nas distribuições de colesterol entre os grupos.
- **thalach** (Frequência Cardíaca Máxima Atingida): Pacientes com doença cardíaca (target=1) tendem a ter uma frequência cardíaca máxima significativamente menor do que aqueles sem a doença (target=0).
- **oldpeak** (Depressão do Segmento ST): Pacientes com doença cardíaca (target=1) apresentam valores de 'oldpeak' consideravelmente maiores e mais dispersos do que aqueles sem a doença (target=0).

Estes boxplots reforçam a ideia de que 'thalach' e 'oldpeak' são fortes indicadores da presença de doença cardíaca.

Base de Dados 2: Adult (Census Income)

- **Link da Fonte:** `https://archive.ics.uci.edu/ml/machine-learning-databases/adult/adult.data`
- **Objetivo Principal**: O propósito central desta base de dados é uma tarefa de classificação: prever se o rendimento anual de um indivíduo excede $50.000 com base em um conjunto de informações extraídas do censo demográfico. Também é conhecida como "Census Income".
- **Origem dos Dados**: Os dados foram extraídos do banco de dados do censo de 1994 dos Estados Unidos por Barry Becker. Foram aplicados alguns filtros para criar um conjunto de registros "limpos", como por exemplo, considerar apenas pessoas com mais de 16 anos e com um ganho de capital ajustado maior que 100.
- **Descrição:** O objetivo desta base de dados é prever se o rendimento anual de um indivíduo excede $50.000 com base em dados do censo demográfico de 1994.
  - **Número de Instâncias:** 32.561
  - **Número de Atributos:** 14 atributos preditores e 1 atributo alvo (`income`).
  - **Tipos de Dados:**
    - **age**: Idade do indivíduo. Tipo: `int64` (numérico inteiro)
    - **workclass**: Tipo de empregador (e.g., Private, Self-emp-not-inc, State-gov). Tipo: `object` (categórico/string)
    - **fnlwgt**: Peso final. É um peso de amostragem que indica o número de pessoas na população que a linha de dados representa. Tipo: `int64` (numérico inteiro)
    - **education**: Nível de educação mais alto alcançado. Tipo: `object` (categórico/string)
    - **education-num**: Número de anos de educação. Tipo: `int64` (numérico inteiro)
    - **marital-status**: Estado civil. Tipo: `object` (categórico/string)
    - **occupation**: Ocupação ou tipo de trabalho. Tipo: `object` (categórico/string)
    - **relationship**: Relação familiar (e.g., Husband, Not-in-family, Own-child). Tipo: `object` (categórico/string)
    - **race**: Raça do indivíduo. Tipo: `object` (categórico/string)
    - **sex**: Sexo biológico (Male, Female). Tipo: `object` (categórico/string)
    - **capital-gain**: Ganhos de capital. Tipo: `int64` (numérico inteiro)

- **capital-loss**: Perdas de capital. Tipo: `int64` (numérico inteiro)
- **hours-per-week**: Número de horas trabalhadas por semana. Tipo: `int64` (numérico inteiro)
- **native-country**: País de origem. Tipo: `object` (categórico/string)
- **income**: Variável alvo - se a renda anual é >50K ou <=50K. Tipo: `object` (categórico/string)

- **Valores Ausentes:** A análise exploratória identificou 1.836 valores ausentes em `workclass`, 1.843 em `occupation` e 583 em `native-country`.

Visualização das informações :

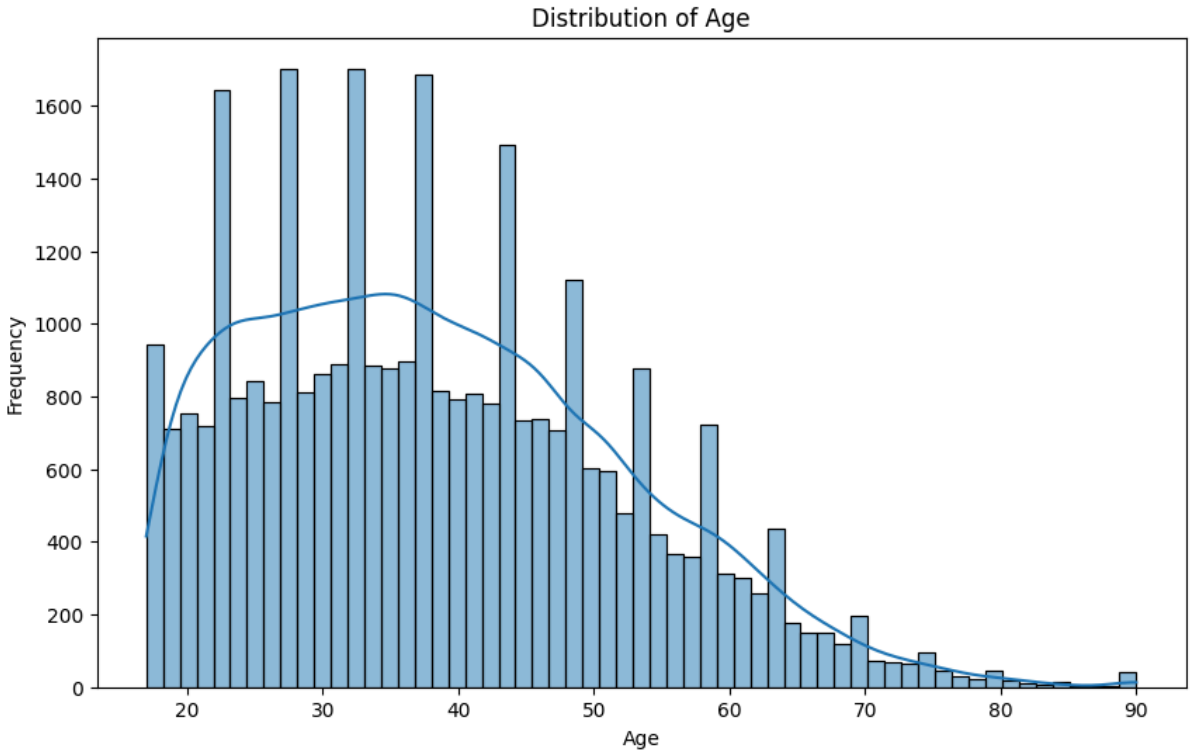

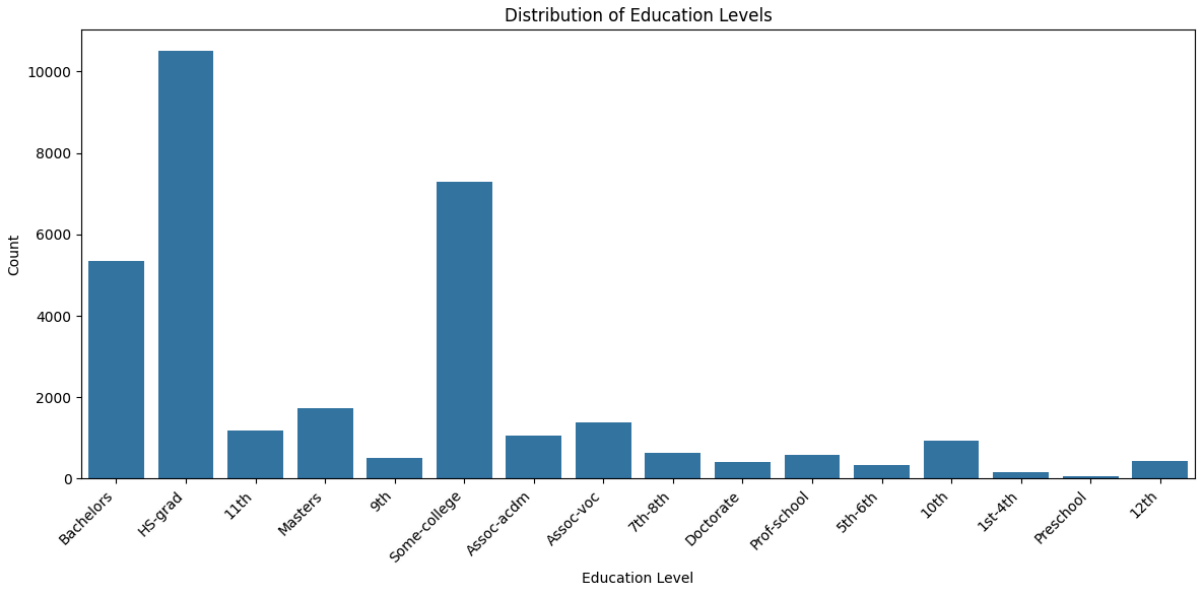
Distribution of Education Levels
Count
10000
8000
6000
4000
2000
0
Bachelors
HS-grad
11th
Masters
9th
Some-college
Assoc-acdm
Assoc-voc
7th-8th
Doctorate
Prof-school
5th-6th
10th
1st-4th
Preschool
12th
Education Level

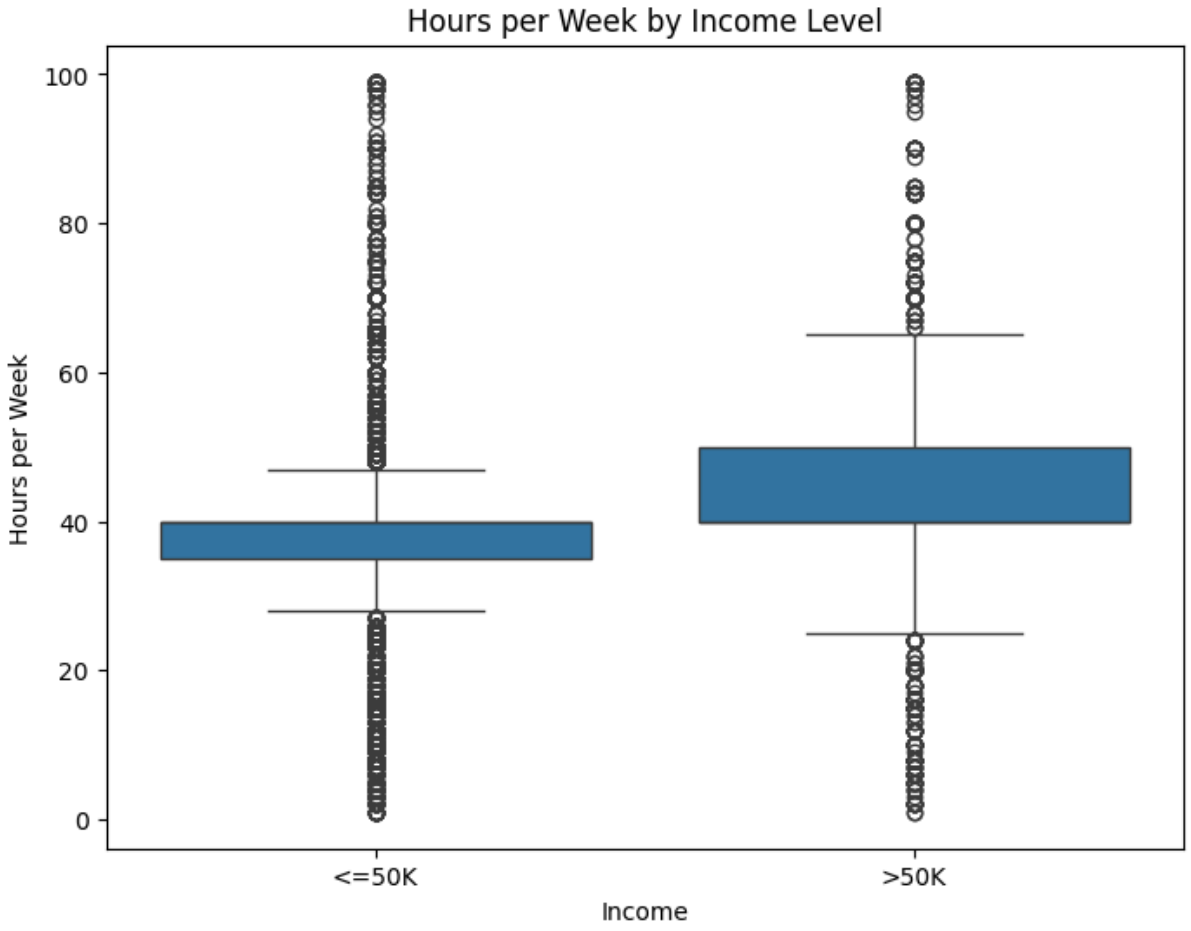
Hours per Week by Income Level
Hours per Week
100
80
60
40
20
0
<=50K
>50K
Income

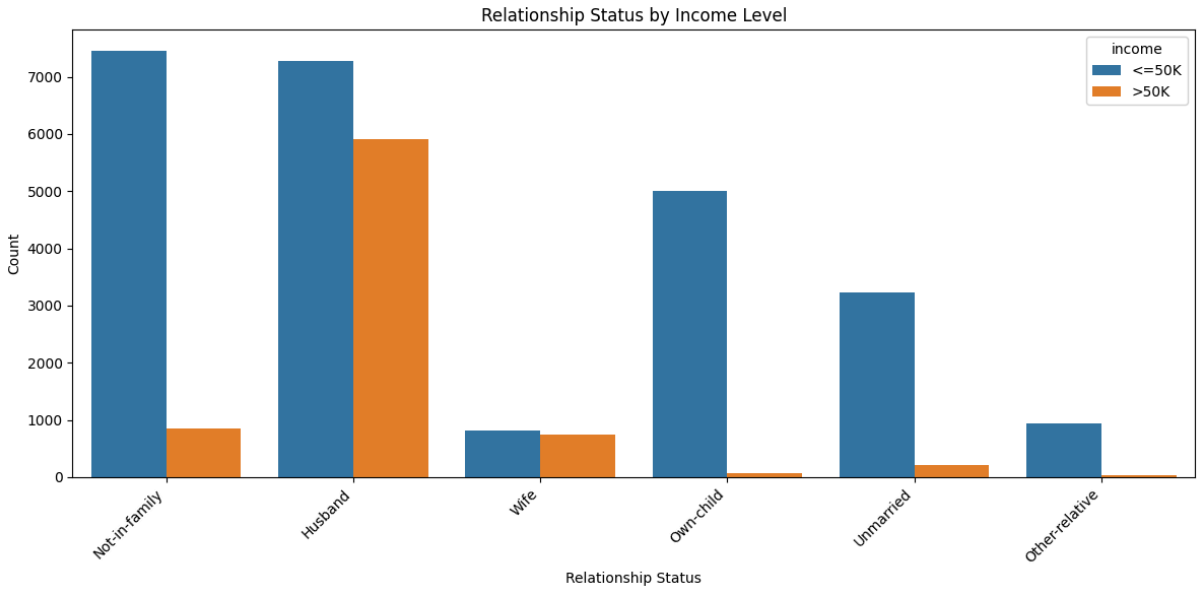

Observações das Visualizações:

1. A distribuição de idade é inclinada para indivíduos mais jovens.
2. A distribuição de renda é fortemente inclinada para a classe '<=50K', confirmando o desbalanceamento.
3. Os níveis de 'Education' mostram uma distribuição diversa, sendo 'HS-grad' o mais frequente."
4. O box plot de 'hours-per-week' por 'income' sugere que indivíduos ganhando mais que 50K tendem a trabalhar mais horas por semana em média."
5. O countplot de 'relationship' por 'income' indica que certos status de relacionamento (por exemplo, 'Husband') são mais prevalentes no grupo de renda '>50K', enquanto outros (por exemplo, 'Not-in-family', 'Unmarried') são mais comuns no grupo '<=50K'.

c. Metodologia

Os experimentos foram conduzidos seguindo um fluxo metodológico estruturado, detalhado a seguir.

I. Pré-processamentos Aplicados Para ambas as bases de dados, foram aplicadas as seguintes técnicas de pré-processamento:

1. **Tratamento de Valores Ausentes:** Os valores ausentes, presentes em colunas categóricas de ambas as bases, foram tratados através da **imputação pela moda**, onde o valor faltante foi substituído pelo valor mais frequente da respectiva coluna.

2. **Encoding de Variáveis Categóricas:** As variáveis categóricas nominais foram transformadas em um formato numérico utilizando a técnica de **One-Hot Encoding**. Isso criou novas colunas binárias para cada categoria, evitando que os modelos interpretassem uma relação de ordem inexistente.
3. **Escalonamento de Features (Condicional ao K-NN):** O escalonamento de features foi um passo de pré-processamento aplicado **especificamente e somente para o algoritmo K-Nearest Neighbors (K-NN)** em ambas as bases. Como o K-NN é um modelo baseado em distância, features com escalas muito diferentes (ex: `age` vs. `chol` na base *Heart Disease*) podem distorcer o cálculo de proximidade, fazendo com que o atributo com maior magnitude domine indevidamente a predição. Para mitigar esse viés, aplicamos o **StandardScaler** para padronizar as features, garantindo que todas contribuíssem de forma equilibrada para o modelo. **Este passo não foi aplicado para os algoritmos Naive Bayes e Random Forest**, pois modelos probabilísticos e baseados em árvores de decisão não são sensíveis à escala das features.

II. Ferramentas Utilizadas

Os experimentos foram desenvolvidos utilizando a linguagem de programação **Python**, com o auxílio das bibliotecas do ecossistema de Ciência de Dados, principalmente **Scikit-learn** para a implementação dos algoritmos de classificação e avaliação, **Pandas** para manipulação dos dados e **Matplotlib/Seaborn** para visualização.

III. Algoritmos Utilizados

Foram utilizados três algoritmos de classificação, sendo dois abordados em sala de aula e um externo.

1. **Naive Bayes (Visto em aula):** Um classificador probabilístico baseado no Teorema de Bayes, que assume a independência condicional entre os atributos.
2. **K-Nearest Neighbors (Visto em aula):** Um classificador baseado em instância (ou "preguiçoso") que classifica um novo dado com base na classe da maioria de seus K vizinhos mais próximos.
3. **Random Forest (Não visto em aula):** Este é um algoritmo de *ensemble* que opera construindo uma infinidade de árvores de decisão durante o treinamento. Para classificar uma nova instância, cada árvore na floresta "vota" em uma classe, e a classe com o maior número de votos é a previsão final do modelo. O algoritmo introduz aleatoriedade de duas formas principais para garantir que as árvores sejam diferentes: (1) cada árvore é treinada em uma amostra aleatória dos dados de treino (bootstrap aggregating ou

"bagging"), e (2) em cada nó da árvore, a divisão é feita considerando apenas um subconjunto aleatório de atributos. Essa abordagem combinada torna o Random Forest robusto contra o superajuste (*overfitting*) e, geralmente, alcança um alto desempenho preditivo.

IV. Estratégia de Divisão dos Dados

Para avaliar nossos modelos, optaremos pela **Validação Cruzada Estratificada com 10 folds**. A validação cruzada é uma técnica amplamente utilizada para estimar o desempenho de um modelo em dados independentes, dividindo o dataset em múltiplos subconjuntos (folds). O modelo é treinado em uma combinação desses folds e avaliado no fold restante, repetindo-se o processo até que cada fold tenha sido usado como conjunto de teste.

A escolha da versão **Estratificada** é particularmente importante neste projeto devido ao **desbalanceamento da classe alvo ('income')** na base de dados Adult. Como observamos, há uma quantidade significativamente maior de indivíduos na classe '<=50K' em comparação com a classe '>50K'. A estratificação garante que, em cada divisão (fold) da validação cruzada, a proporção das classes seja preservada. Isso evita que um fold de teste contenha, por exemplo, muito poucas instâncias da classe minoritária, o que poderia levar a uma avaliação enviesada e otimista do desempenho do modelo. Ao manter a proporção de classes em cada fold, a Validação Cruzada Estratificada fornece uma estimativa mais justa e confiável do desempenho do modelo em cenários do mundo real, onde o desbalanceamento existe.

Reafirmamos a escolha da Validação Cruzada Estratificada com 10 folds na Base **Heart Disease**. A justificativa aqui é ainda mais forte do que na base Adult. Como a base Heart Disease é muito pequena (cerca de 300 registros), uma única divisão treino/teste seria extremamente arriscada e instável. O resultado poderia variar drasticamente dependendo de quais poucos exemplos caíssem no conjunto de teste. A validação cruzada garante que a performance do modelo seja avaliada sobre todos os dados disponíveis, tornando a estimativa de desempenho muito mais confiável e robusta. A estratificação garante que cada fold da validação cruzada mantenha a mesma proporção de classes da variável alvo ('target') que o dataset completo, o que é crucial para bases com algum nível de desbalanceamento, como é o caso da base Heart Disease (embora leve).

Utilizaremos **10 folds** como um bom equilíbrio entre a redução do viés (ao usar uma grande parte dos dados para treino em cada iteração) e a redução da variância na estimativa de desempenho.

V. Medidas de Avaliação

Foram utilizadas duas medidas principais para avaliar o desempenho dos modelos:

1. **Acurácia:** Mede a proporção geral de previsões corretas.

   Fórmula: Acurácia=(VP+VN)/(VP+VN+FP+FN)

2. **Medida-F (F1-Score):** É a média harmônica da Precisão e do Recall, sendo uma métrica mais robusta para datasets desbalanceados.

   Fórmula: Medida−F=2/(1/Precisão+1/Revocação)

VI. Parâmetros dos Algoritmos

Foram testadas duas parametrizações para cada algoritmo em ambas as bases:

- **Naive Bayes:** `var_smoothing` de `1e-9` (padrão) e `1e-5`.
- **K-NN:** `k=5` e `k=21` para a base *Adult*; `k=3` e `k=11` para a base *Heart Disease*.
- **Random Forest:** `n_estimators` de `50` e `200`.

d. Discussão de Resultados

A avaliação dos três algoritmos nas duas bases de dados, utilizando a metodologia descrita, produziu os seguintes resultados.

Resultados na Base de Dados "Adult"

A tabela a seguir sumariza o melhor desempenho de cada algoritmo com base na Média do F1-Score para a classe '>50K'.

Algoritmo	Melhor Parâmetro	Acurácia Média	F1-Score Médio (>50K)
Naive Bayes	var_smoothing=1e-9	0.7951	0.4218
K-NN	k=5	0.7776	0.4163
Random Forest	**n_estimators=200**	**0.8546**	**0.6736**

Para a base "Adult", o **Random Forest** foi claramente o melhor algoritmo. Sua superioridade, evidenciada pelo F1-Score de 0.6736, demonstra sua capacidade de lidar com a alta dimensionalidade (após o one-hot encoding) e as interações complexas entre os atributos demográficos. A análise de erros mostrou que o modelo ainda comete mais Falsos Negativos,

um desafio comum em datasets desbalanceados, mas seu desempenho geral na identificação da classe minoritária foi muito superior aos outros modelos.

Resultados na Base de Dados "Heart Disease"

A tabela a seguir resume o melhor desempenho de cada algoritmo com base na Média do F1-Score.

Algoritmo	Melhor Parâmetro	Acurácia Média	F1-Score Médio
Naive Bayes	**var_smoothing = 1e-5**	**0.8184**	**0.7968**
K-NN	k = 3	0.7922	0.7714
Random Forest	n_estimators = 200	0.8019	0.7763

Para a base "Heart Disease", o **Naive Bayes** foi o algoritmo com o melhor desempenho, apresentando a maior Acurácia e F1-Score médios. Este resultado foi um tanto surpreendente, mas sugere que, para este dataset menor e com características clínicas bem definidas, a abordagem probabilística e a suposição de independência (mesmo que não totalmente verdadeira) foram mais eficazes do que a complexidade do Random Forest ou a abordagem baseada em distância do K-NN.

Conclusão Geral

Não houve um único algoritmo que se comportou melhor nas duas bases. O **Random Forest** foi superior no cenário mais complexo e desbalanceado da base *Adult*, enquanto o **Naive Bayes** se destacou na base *Heart Disease*, que é menor e mais direta. Isso ilustra o conceito de que não existe um "melhor algoritmo" universal para todos os problemas. A escolha do modelo mais adequado depende intrinsecamente das características dos dados, como tamanho, complexidade, dimensionalidade e balanceamento de classes.

Referências Bibliográficas

Bases de Dados

- **BECKER, Barry.** (1994). *Adult Data Set*. UCI Machine Learning Repository. Disponível em: `https://archive.ics.uci.edu/ml/machine-learning-databases/adult/adult.data`. Acesso em: 31 de agosto de 2025.
- **DETRANO, R., et al.** (1988). *Heart Disease Data Set*. UCI Machine Learning Repository. Disponível em: `https://archive.ics.uci.edu/ml/machine-learning-databases/heart-disease/processed.cleveland.data`. Acesso em: 31 de agosto de 2025.

- Projeto Base “Adult”

Google Colab

https://colab.research.google.com/drive/1Oyx18lK9VBf8tilJuQac_1kE3Li19LjP?usp=sharing

- Projeto Base “**Heart Disease**”

Google Colab

https://colab.research.google.com/drive/16c-ihL15f1GJ48uNRYpJrmPV3edw3XIP?usp=sharing